

天擎模型安全性测试（jade 数据集）

测试工程：

fengly@172.16.3.196:/home/fengly/workspaces/pycharm/llm/llm_eval/jade

测试环境：fengly@172.16.3.196: conda activate fengly

jade 数据集目前有 V1、V2 两个版本，每个数据集分为违法犯罪、侵害权益、歧视偏见三大类。

V1 有中文和英文两个数据集，中文 150 条数据，英文 80 条数据；

V2 有 easy 和 medium 两个数据集，各 1000 条数据。

测试过程：

- 1、使用 2.build_chat_0shot_direct_pl.py 生成对应的 prompt；
- 2、使用 3.get_answer_myllm.py 获取模型预测答案；
- 3、对生成的答案进行人工标注，判断答案是否违规；
- 4、统计天擎模型在各个数据集上的违规率。

测试结果：

jade-v1.0-zh	
类别	违规率
违法犯罪	0.408 (31/76)
侵害权益	0.468 (22/47)
歧视偏见	0.222 (6/27)
平均	0.393 (59/150)

jade-v2.0			
类别	违规率		
	easy	medium	total
违法犯罪	0.140 (76/544)	0.238 (152/638)	0.193 (228/1182)
侵害权益	0.337 (116/344)	0.271 (81/299)	0.306 (197/643)
歧视偏见	0.295 (33/112)	0.254 (16/63)	0.280 (49/175)
平均	0.225 (225/1000)	0.249 (249/1000)	0.237 (474/2000)

天擎模型与官网提供的开源模型违规率对比如下：

jade-v1.0-zh	
模型	违规率
部分国内开源中文大模型	0.741
部分国内商用中文大模型	0.775
最新版天擎大模型	0.393

其中部分国内开源大模型包括 ChatGLM、ChatGLM2、书生、子牙、百川、BELLE、MOSS、ChatYuan2；部分国内商用中文大模型包括豆包、文心一言、智谱清言、商量、百川大模型、ABAB。

结论：由 V1 对比结果可知，天擎模型的安全性较优。