

基于Adapter的微调方法

一、简介

一种高效的微调方法，将大预言模型微调为跟随指令的模型。对于 llama7b 模型来说，可训练参数缩小到 1.2M，只需要 1 小时即可完成 52K 数据微调 (基于 8xA100 训练)，比 Alpaca 快 3 倍。

Model	Tuned Params	Storage Space	Training Time
Alpaca [41]	7B	13G	3 hours
Alpaca-LoRA [12]	4.2M	16.8M	-
LLaMA-Adapter	1.2M	4.7M	1 hour

Table 3. **Efficiency Comparison** of instruction-following methods. The training time is tested on 8 A100 GPUs.

LLaMA-Adapter论文链接: [2303.16199] [LLaMA-Adapter: Efficient Fine-tuning of Language Models with Zero-init Attention \(arxiv.org\)](#).

二、方法

下图为Adaper、P-tuning、LST（类似LoRA）3中微调方法的对比。




Figure 2: Comparison between transfer learning with (a) Adapters, (b) Prompt Tuning, and our (b) Ladder Side-Tuning (LST). LST reduces memory usage by removing the need of backpropagation through backbone networks.

LLaMA-Adapter的微调方案如下图所示，在传统的Adapter方法上做了改进，冻结原始模型参数，只在深层网络中额外添加一个轻量级的自适应器进行微调。




Figure 2. **Details of LLaMA-Adapter.** We insert lightweight adapters with learnable prompts into L out of N transformer layers of LLaMA. Aided by zero-init attention and gating mechanisms, the adaption prompt progressively learns new instructional cues, without disturbing the original pre-trained knowledge.

具体操作：

- 在原LLaMA模型的深层 transformer 中插入adapter，即一组可学习的自适应提示作为前缀附加到输入指令 token 中。通过提示学习将新指令自适应地注入 LLaMA，更好地调整具有高级语义的语言表示。
- 为避免在训练开始阶段适应提示中的噪声，将插入层的 attention 机制修改为零初始 attention，并使用可学习的门控因子。这样可以先保留 LLaMA 中的原始知识，在训练过程中逐步引入指令信号。

优点：

- 对于不同的场景可以在基础的 llama 模型 上插入不同的插件小模型，用于处理不同场景任务。

三、代码

1. lit-llama

提供了 finetune_adapter.py 微调脚本

项目地址: [Lightning-AI/lit-llama: Implementation of the LLaMA language model based on nanoGPT. Supports flash attention, Int8 and GPTQ 4-bit quantization, LoRA and LLaMA-Adapter fine-tuning, pre-training. Apache 2.0-licensed. \(github.com\)](https://github.com/Lightning-AI/lit-llama)

2. llama-adapter

提供了对7B模型的微调脚本finetuning.py

项目地址: [ZrrSkywalker/LLaMA-Adapter: Fine-tuning LLaMA to follow Instructions within 1 Hour and 1.2M Parameters \(github.com\)](https://github.com/ZrrSkywalker/LLaMA-Adapter)

四、实验验证

微调数据集: alpaca_gpt4_data_zh.json

微调模型: 7B (65B的显存不够)

代码: lit-llama

硬件环境: 2张3090

实验对比:

- adapter会报错显存不足;
- 用lora可以, 微调保存的参数大小为8M (迭代3.5w次共训练了5.5h)