

Resume



彭闯

籍贯：陕西

手机：17798558749

年龄：29 岁

居住地：西安市 高新区

学历：硕士研究生

微信：pcc597911

政治面貌：入党积极分子

求职意向：算法工程师



教育经历(Education)

2017-09-01~2020.3

南京邮电大学 (双一流)

硕士

应用统计

主修课程：机器学习 / 统计学习方法 / 机器学习与模式识别 / 大数据统计模型 / 多元统计 / 复杂数据统计方法

2012-09-01~2016-06-30

陕西师范大学 (211)

本科

金融学

主修课程：微观经济学/宏观经济学/金融学/高等数学/数学分析



工作经历(Intern Experience)



厦门市美亚柏科信息股份有限公司

nlp 算法工程师

2020.6-至今

自 2020 年 6 月加入美亚柏科装备设计研究院-AI 研发中心

1、2020 年 6 月-2020 年 12 月，负责 nlp 基础工具的优化，主要负责 nlp 分词及预处理工具的加速与算法优化，利用算法优化、cython 加速、重构 cppjieba 核心代码等手段，提升产品端数据预处理的处理速度，为中心其他的 nlp 算法进行优化和赋能。

2、2021 年 1 月-2021 年 12 月，负责公司美亚大脑项目情感分析模型的构建及 SDK 的编写，负责数据清洗、模型训练、模型调优、产品嵌入的全流程工作。期间利用知识蒸馏、损失函数改写、数据增强等手段优化情感分析的效果。

3、2022 年 1 月-2023 年 2 月，负责公司产品图数据库的构建，建立相应的产品知识图谱，利用 texttosql 技术生成文本的自动查询。合作开发内部助手 gpt 和小美，提供利用意图分类和 slot 识别模型和其他部门合作开发了智能助手工具。

4、2023 年 3 月-至今，参与公司天擎大模型的研发，负责模型的前期调研，数据收集，事后检索增强等项目，参与了大模型的全量微调、增量微调、检索优化、长度扩充等过程。最终完成了天擎的第一版大模型的发布。

参与车牌疲劳驾驶识别、非法营运车辆识别、分心驾驶等数据分析任务，利用 sql 数据库查询以及 xgboost、随机森林、svm 等多种模型建模，参与数据提取、数据清洗、数据建模、报告编写等一系列工作。



项目经历(project Experience)

Nlp 基础工具优化及项目嵌入

2020-06-2020- 12

为了提升公司产品端竞争力，加快各个产品中 NLP 各类任务的推理速度，负责了 NLP 基础包分词和预处理的算法优化，将产品预处理时间缩短 50%，提升各个 nlp 任务推理速度 100%以上。

1、负责分词算法改写：通过算法层面优化分词步骤，采用后向分词+HMM+前缀树的数据结构改写 jieba 的分词逻辑，利用 cython 等工程化工具加快组件的推理速度，利用 HMM 模型优化模型在专用领域的分词效果。并分别改写 python 和 c++两个版本，相对比于原版分词，提升推理速度 100%。

2、分词算法的工程化嵌入：将新的分词算法，进行工程化嵌入，按照业务逻辑完成正则过滤、常用符号过滤、分词、fastjson 等处理过程，利用 c++编写为 sdk 嵌入产品端提升产品端推理速度 1 倍以上。

情感分析模型训练及产品端嵌入

2021 年 1 月-2021 年 12 月

为了新增公司产品对情感分析的需求，利用 tensorflow、pytorch 等多种深度学习框架训练与嵌入了情感分析模型与 sdk，负责模型的选型、训练、产品端加速、后期的维护与优化。主要包括以下任务：

1、情感分析模型训练：预研了 Textcnn、Texttrnn、Textrcnn、Dpcnn、transformers 等一系列主流分类模型，最终选用 textcnn+attention+tensorflow 作为分类模型主流技术栈，利用 focal_loss、软间隔等优化交叉熵，使用 openvino、tensorRT、mn 进行模型的 sdk 嵌入加速，最终模型在 gpu 最高推理速度 30000 段每秒，负面和 F1 达到 87%和 83%。

2、情感分析模型优化：利用词向量压缩检索、数据替换增量等多种手段解决训练样本的不均衡问题，使用 pytorch 搭建 bert-子模型的蒸馏框架，构建模型的一键式训练转换（torch-onnx-openvino 和 trt），提升模型负面和 F1 检索达到 87%和 91%。

智能指令输出和小型 gpt 构建

2022 年 1 月-2023 年 2 月

1、图数据库的智能指令输出：负责图数据库的 arangodb 的构建，基于 arangodb 为基础图数据库，使用 c++代码进行图数据库的建库、入库、删除等指令，使用对应表内关系进行人物、事件的三元关系构建，基于 pytorch 框架对 bert-wrm 的 texttosql 模型训练，利用实体+text 的数据构建方式优化 texttosql 结果，在验证数据准确率达到 95%。构建 text-sql-图数据库输出的闭环输出。

2、gpt 意图实体模型产品端合作：负责模型的选型，使用 pytorch 框架和 jointbert 模型，进行 text 到意图端和实体端的模型训练，利用正则改写时间转换函数和自编写分词脚本提升模型在专用领域的准确率，模型最终经过多步迭代在验证集准确率达到 95%。负责模型的产品嵌入，嵌入开发 openvino、trt 两个版本。

天擎大模型训练与发布

2023 年 3 月-至今

3.2 my 天擎模型的发布

在算力与 gpt3.5 影响下，公司需要一款属于自己的大模型在市场中提升竞争水平，同时也为后期的 sdk 等多种 ai 项目提供基准 ai 需求与对接。我这里主要负责以下几种任务：

- 1、参与模型前期的预研与选择，包括大模型数据集的收集、base 模型的选择，微调方式的调研 lora。最终在多人合作下，最终确定了 base 模型方案。
- 2、参与数据清洗与模型微调，使用产品数据增量训练+Lora 微调的方式对大模型进行迭代，将产品数据与通用数据通过 1:1 混合的方法在 16 张 H800 的迭代 1 个月完成大模型的增量迭代。利用多种微调数据对大模型进行相应的微调处理，包括人类价值观对齐、安全观处理、产品问答数据集、通用指令数据集等多种微调方式。将 ziya 在测评数据集的得分提升 11%。
- 3、参与模型的长度外推训练：使用 (RoPE) 旋转位置编码技术，扩充模型的输入长度至 4096。构建外推数据集对大模型进行长度的外推编码。
- 4、优化模型的发条检索。由于大模型后期需提供给 gz 使用，需要保证模型对法律、发条等输出的完全正确性。这里采用数据库检索+模型微调输出方式改变法律的整体输出，利用模型输出发条前缀，采用迭代后的 bge 对发条前缀进行检索生成。提升发条输出正确率至 80%（最开始模型的输出基本都是错误的）



获奖情况(Awards)

竞赛经历

全国大学生统计建模大赛二等奖	2018-05
数学建模大赛二等奖	2020-01
百度人工智能大赛二等奖	2022-03

专利

- 《基于分词的快速预处理方法》
- 《一种融合多特征图的注意力机制的不良文本分类方法》
- 《基于多模态检索和主题词 RNN 的数据增强方法》
- 《一种基于时序句子特征的社交文本情感分类》
- 《一种基于图卷积网络的社交文本分类方法》
- 《一种基于自构建词典的提示模板构建方法》

证书

英文 6 级（英语可作为日常交流语言）
计算机二级



职业技能(professional Skill)

Python(熟练)/c++（掌握）/linux(熟练)/docker(熟练) tensorflow/pytorch(掌握)



自我评价(Self-assessment)

本人做事认真负责，为人真实，工作积极，乐于与人沟通交流，能很好的与人相处。，了解统计学模型的基本原理、基本理论及机器学习的相关建模原理，有三年 nlp 相关的经验，了解 nlp 的底层逻辑和相应的算法，了解 pytorch、tensorflow 等深度学习框架，有 nlp 相关的项目经验。