

Resume



彭闯

籍贯：陕西

手机：17798558749

出生年月：1994.03.30

备用电话：18829286067

学历：硕士研究生

邮箱：1273138954@qq.com

政治面貌：入党积极分子

职业：nlp 算法工程师



教育程度(Education)

2017-09-01~2020.3

南京邮电大学 (双一流)

硕士

应用统计

主修课程：应用数理统计 (93) 国际金融 (92) 时间序列分析-基于 r (90) 统计软件与应用 (90)

2012-09-01~2016-06-30

陕西师范大学 (211)

本科

金融学

主修课程：微观经济学 (89) 宏观经济学 (92) 金融学 (90) eviews 与应用 (89)



职业技能(Skill)

- 熟悉 python 编程，了解 c++。
- 了解 mysql、oracle 等数据库，熟悉 linux 命令操作。
- 了解各种 nlp 基础组件的应用包括分词工具、相似词检索、词向量压缩与训练等多种 nlp 基础模块的原理与应用
- 了解常见的深度学习的框架包括，pytorch、tensorflow 等框架，了解各类模型的多元平台部署，包括 trt、openvino、mnn 等框架的模型部署。了解常见的深度学习模型包括 textcnn、textrnn、bert、transformer 等。



工作经历(Intern Experience)

- 公司：**南京烽火通信有限公司 **时间：**2019.7-2020.1 **职位：**数据挖掘实习
- 利用 oracle、Fpointer 等软件进行 sql 查询、挖掘语句的书写撰写报告
- 利用 python 生成 sql 的自动化报告，利用集群后台生成数据的自动导入
- 利用爬虫获取公司的评论，利用朴素贝叶斯进行公司的评论分类。
- 参与车辆疲劳驾驶识别，进行建模与调参分析，主要是分类模型，包括 xgboost、随机森林、svm 等常见的分类模型。
- 利用业务逻辑解决交管的实际问题，包括非法营运车辆的识别、分心驾驶行为的识别。

● **公司：**厦门市美亚柏科信息股份有限公司

时间：2020.6-至今

职位：nlp 算法工程师

项目 1 nlp 基础工具的优化

1、jieba 分词工具的速度优化与任务优化 (2020.6-2020.12)

学习 jieba 分词工具的原理，通过算法层面改写分词工具的原理，让 jieba 分词和 jieba_fast 分词再原有的基础上提升 1 倍以上的分词速度。优化分词的准确率使得分词在公司专用领域的数据集中分词的 F1 值提升 9%。改写 cppjieba 源代码，在损失 2%精度的情况下提升分词速度 1 倍以上。

该项目通过 c++sdk 嵌入和训练方式，嵌入了公司相应的项目中，打包为数据预处理的 sdk 程序，优化了所有 nlp 基础组件的速度，包括下游的情感分析、sa 分析、ql 分析等等多个项目，提升了项目整体的运行速度 40% 及以上。

2、情感分类模型搭建

(1) 负责基础模型的训练

搭建情感分类模型，进行模型的封装和迭代，以及模型的转化。模型分别搭建为 TensorFlow 版本、pytorch 版本。利用 c++代码将其分别转为 trt (gpu)、mnn(cpu 国产 阿里版本)、openvino(cpu)三种 sdk 的形式。其中 trt 版本的 sdk 相比于 tensorflow 版本提升速度 100%，cpu 版本提升速度 80%。

(2) 情感分析模型的优化

方式 1:

使用数据增强的技术，利用词向量检索和 nlpcda 的包完成少样本的数据增强，并应用于 text_cnn 中，经过数据增强后的模型分类效果明显提升，F1 平均提升 7%左右

方式 2:

采用知识蒸馏的方式，将 bert 模型以模型蒸馏的方式，将其中的知识充分让下游的 textcnn 进行学习，并将其转为 onnx 模型，利用自动化脚本将其转为 trt 和 openvino、mnn 的三种框架，提升模型相应的泛化性。

3、gpt 相关项目。

3.1 mygpt 意图模型的搭建

1、初始化模型迭代

利用 joint-bert 模型进行实体识别和文本分类的模型训练，完成 joint-bert 的实体和文本分类模型的搭建。

其中添加时间转换函数(由自己编写的时间转换<正则+时间转换>和第三方时间转换的包)共同完成时间的标准转换。其次需要在其中加入错别字的纠错模型，这里首先使用的是 pycorrect 的第三方包，但是由于其中的 bert 模型无法对词进行 mask 掩码，为了纠正这一错误，将模型换成了 bert-wwwm 进行词的掩码操作。

2、模型的各个版本的平台部署

部署模型至各个版本，包括 sdk 版本，c++编写 openvino、trt、mnn 三个版本。部署模型至 linux 服务器，采用 cython 进行模型的加密以及采用 flask_restful 的方式加载模型的服务接口，利用服务接口进行相应

的调用。

3.2 my 天擎模型的开发

1、参与天擎模型前期的调研与开发

(1) 参与 gpt 模型的调研，确定整体模型的选型（选择哪个大模型为基座模型），确定前期大模型的投入方案，包括微调的方式的选择，数据的收集等等。

2、参与模型的后期微调

(1) 参与天擎模型的微调，以 lora 的方式，采用制作的多轮问答集和单轮问答集进行相应的模型微调，并进行相应的评测，提升大模型在公司产品数据的理解力。

(2) 以 fastchat 为框架，进行模型后检索的修改，修正模型对发条数据的完全替换，优化模型的检索效果。

3、参与模型的平台部署

将模型部署至各个服务器，包括 docker 容器的迁移，环境的打包，bash 脚本的编写等等。



获奖情况(Awards)

公司获奖情况

国家级：

全国大学生统计建模大赛二等奖（2019）（图像识别方向） 大学时期

百度人工智能大赛二等奖（2020） 错别字识别分类

专利：

发表专利 6 篇

《基于分词的快速预处理方法》

《一种融合多特征图的注意力机制的不良文本分类方法》

《基于多模态检索和主题词 RNN 的数据增强方法》

《一种基于时序句子特征的社交文本情感分类》

《一种基于图卷积网络的社交文本分类方法》

《一种基于自构建词典的提示模板构建方法》

获得公司季度优秀员工一次

英文水平：CET-4, CET-6，能够正常阅读外文及英文文献，能够正常在英文及各类最新的工程说明网站上进行相应说明文档的阅读及相应问题的查找。



自我评价(Self-assessment)

本人做事认真负责，为人真实，工作积极，乐于与人沟通交流，能很好的与人相处。学习能力强，了解统计学模型的基本原理、基本理论及机器学习的相关建模原理，有三年 nlp 相关的经验，了解 nlp 的底层逻辑和相应的算法，了解 pytorch、tensorflow 等深度学习框架，有 nlp 相关的项目经验。